

Tutorial Master: Big Data Analytics para Classificação de Filmes

1. Contexto Estratégico e Objetivos do Projeto

No ecossistema hipercompetitivo do streaming, a plataforma **Start-Flix** enfrenta uma estagnação crítica de engajamento. Embora possua um vasto repositório de dados — o "petróleo bruto" da economia digital — a empresa falha em refinar esse volume em inteligência acionável. A ausência de personalização resulta em recomendações genéricas que ignoram as nuances dos usuários, gerando frustração e abandono da plataforma. Este projeto estabelece a fundação técnica para solucionar três pilares de dor do negócio:

1. **Recomendações Ineficientes:** Identificaremos como a falta de cruzamento entre dados comportamentais e demográficos limita a conversão.
2. **Falta de Insights:** Analisaremos tendências temporais e de gênero para orientar a aquisição de conteúdo.
3. **Desempenho de Filmes:** Utilizaremos a **Teoria da Cauda Longa** para entender a concentração de popularidade e identificar "joias escondidas" que podem reter nichos específicos de usuários. Antes da análise, estruturaremos um ambiente escalável e reprodutível, essencial para qualquer Arquiteto de Big Data.

2. Configuração do Ecossistema de Trabalho

A reprodutibilidade é a métrica de qualidade de um Cientista de Dados Sênior. Utilizaremos a nuvem para processamento e o GitHub para versionamento e portfólio. **Passo a Passo de Configuração:**

- **Repositório de Portfólio:**
- Acesse o GitHub e crie o repositório público MEUS PROJETOS.
- **Importante:** Acesse o repositório de referência do projeto em <https://github.com/PROFSANTARELLI/BIG-DATA> para obter os scripts base e dados complementares.
- **Ambiente de Execução (Google Colab):**
- Acesse o Google Colab com sua conta Google.
- Crie um "Novo Notebook". O Colab fornece instâncias de hardware otimizadas para processar os milhões de registros que manipularemos.

3. Aquisição e Ingestão de Dados (Kaggle e Colab)

Trabalharemos com o dataset **MovieLens 20M**, o padrão ouro da indústria para sistemas de recomendação. **Procedimento de Carga:**

- **Fonte dos Dados:** Acesse o Kaggle - MovieLens Dataset.
- **Download Seletivo:** Baixe exclusivamente os arquivos movie.csv e rating.csv.
- **Preparação: Atenção:** Os arquivos vêm compactados (.zip). Você **deve descompactá-los** em sua máquina local antes do upload, pois o script espera o formato .csv bruto.
- **Ingestão no Colab:**
- No menu lateral esquerdo do Colab, clique no ícone de **"Pasta"**.

- Clique no ícone de **"Upload"** (página com seta para cima).
- Selecione os arquivos movie.csv e rating.csv.

4. Fase 1: Processamento, Limpeza e Engenharia de Atributos

Em Big Data, a limpeza consome 80% do tempo. Dados mal estruturados em uma base de 20 milhões de linhas resultam em falhas catastróficas de memória e viés analítico. **Lógica Técnica Aplicada:**

- **Slicing de Títulos:** Removemos os últimos 7 caracteres dos títulos (os anos entre parênteses) após a extração para limpar as strings.
- **Otimização de Memória:** Convertemos gêneros para bool (via get_dummies). Processar strings em 20 milhões de linhas é computacionalmente proibitivo; tipos booleanos reduzem drasticamente o consumo de RAM.
- **Consistência Temporal:** Convertemos timestamps de avaliações em anos inteiros para permitir o agrupamento cronológico.

```
# Bloco 1: Importação e Configuração de Estilo
from timeit import default_timer
import pandas as pd
import numpy as np
import matplotlib.pyplot as plt

start = default_timer()
plt.style.use('ggplot')

# Bloco 2: Carga de Dados
st = default_timer()
movies = pd.read_csv('/content/movie.csv')
ratings = pd.read_csv('/content/rating.csv')

# Bloco 3: Processamento e Limpeza Rigorosa
# Ordenação inicial para integridade de índices
movies.sort_values(by='movieId', inplace=True)
movies.reset_index(inplace=True, drop=True)
ratings.sort_values(by='movieId', inplace=True)
ratings.reset_index(inplace=True, drop=True)

# Engenharia de Atributos: Títulos e Anos
movies['year'] = movies.title.str.extract("\\(\\d{4}\\)", expand=True)
movies.year = pd.to_datetime(movies.year, format='%Y').dt.year
movies.title = movies.title.str[:-7] # Remoção do ano da string do
título

# Engenharia de Atributos: Gêneros (Otimização Big Data)
genres_unique =
pd.DataFrame(movies.genres.str.split('|').tolist()).stack().unique()
```

```

genres_unique = pd.DataFrame(genres_unique, columns=['genre'])
movies = movies.join(movies.genres.str.get_dummies().astype(bool))
movies.drop('genres', inplace=True, axis=1)

# Normalização Temporal de Avaliações
ratings.timestamp = pd.to_datetime(ratings.timestamp,
infer_datetime_format=True)
ratings.timestamp = ratings.timestamp.dt.year

# Tratamento de NaNs e Finalização
movies.dropna(inplace=True)
ratings.dropna(inplace=True)

movies.sort_values(by='movieId', inplace=True)
ratings.sort_values(by='movieId', inplace=True)
movies.reset_index(inplace=True, drop=True)
ratings.reset_index(inplace=True, drop=True)

runtime = default_timer() - st
print(f"Fase 1 concluída. Tempo de execução (sec): {round(runtime,
2)}")

```

5. Fase 2: Análise Exploratória e Visualização de Dados (EDA)

A visualização é a interface entre a ciência e a decisão executiva. Criaremos quatro blocos de visualização para diagnosticar a saúde da Start-Flix.

Bloco A: Volume de Lançamentos vs. Engajamento

Identifica se a produção de conteúdo está sendo acompanhada pelo interesse do público.

```

dftmp = movies[['movieId', 'year']].groupby('year')
fig, ax1 = plt.subplots(figsize=(10,5))
ax1.plot(dftmp.year.first(), dftmp.movieId.nunique(), "g-o")
ax1.set_ylim(0,)
ax1.set_xlabel('Year')
ax1.set_ylabel('Nº Filmes lançados por Ano')

ax2 = ax1.twinx()
dftmp_ratings = ratings[['rating', 'timestamp']].groupby('timestamp')
ax2.plot(dftmp_ratings.timestamp.first(),
dftmp_ratings.rating.count(), "r-o")
ax2.set_ylim(0,)
ax2.set_ylabel('Numero de Avaliações')
plt.title('Filmes por Ano e Volume de Avaliações')
plt.show()

```

Bloco B: Acúmulo por Gênero (Tendência de Mercado)

Demonstra o crescimento cumulativo. Nota: O total de marcações é superior ao de filmes, pois um título pode ter múltiplos gêneros.

```
plt.figure(figsize=(10,5))
dftmp = movies[['movieId', 'year']].groupby('year')
df = pd.DataFrame({'All_movies' : dftmp.movieId.nunique().cumsum()})

for genre in genres_unique.genre:
    dftmp_g = movies[movies[genre]][['movieId',
'year']].groupby('year')
    df[genre] = dftmp_g.movieId.nunique().cumsum()

df.fillna(method='ffill', inplace=True)
df.loc[:,df.columns!='All_movies'].plot.area(stacked=True,
figsize=(10,5))
plt.plot(df['All_movies'], marker='o', markerfacecolor='black',
label='Total Real')
plt.title('Crescimento Acumulado por Gênero')
plt.legend(loc=(1.05,0), ncol=2)
plt.show()
```

Bloco C: Dispersão de Ratings (Viés de Nostalgia)

Analisa se a qualidade percebida (notas) cai com a modernização da plataforma.

```
dftmp = movies[['movieId', 'year']].set_index('movieId').join(
    ratings[['movieId', 'rating']].groupby('movieId').mean())
plt.figure(figsize=(10,5))
plt.plot(dftmp.year, dftmp.rating, "g.", markersize=4)
plt.xlabel('Ano')
plt.ylabel('Taxa média de filmes')
plt.title('Distribuição de Avaliações ao Longo dos Anos')
plt.ylim(0,5)
plt.show()
```

Bloco D: A Teoria da Cauda Longa

Prova que a maioria do catálogo recebe poucas avaliações, exigindo melhores algoritmos de descoberta.

```
dftmp = ratings[['userId', 'movieId']].groupby('movieId').count()
dftmp.columns=['num_ratings']

plt.figure(figsize=(15,5))
```

```
plt.scatter(dftmp.index, dftmp.num_ratings, edgecolor='black',
alpha=0.5)
plt.title('Distribuição de Popularidade (Cauda Longa)')
plt.xlabel('ID do Filme')
plt.ylabel('Número de Avaliações Recebidas')
plt.show()

plt.figure(figsize=(15,5))
plt.hist(dftmp.num_ratings, bins=100, edgecolor='black', log=True)
plt.title('Frequência de Popularidade (Escala Logarítmica)')
plt.xlabel('Número de avaliações recebidas')
plt.ylabel('Número de filmes')
plt.show()
```

6. Síntese de Insights e Recomendações Estratégicas

Observação do Gráfico, Impacto no Negócio (Start-Flix)

Queda de avaliações pós-2015, Risco crítico de churn; os novos lançamentos não estão retendo o público.

Domínio de Drama/Ação, Direcionamento de verba para originais nestes gêneros de alto volume.

Viés de Nostalgia, "Filmes antigos são ""porto seguro"" de qualidade; criar coleções ""Clássicos Imperdíveis""."

Efeito Cauda Longa, "O sistema atual foca no ""Blockbuster""; 90% do catálogo está invisível."

Propostas de Arquitetura de Recomendação:

- **Sistemas Híbridos:** Implementar Filtragem Colaborativa (usuário-usuário) com Baseada em Conteúdo (metadados) para mitigar o problema de *Cold Start*.
- **Factorization Machines:** Essencial para capturar interações complexas entre variáveis esparsas (usuário x filme x gênero).
- **Graph Neural Networks (GNN):** Para mapear relações de interesse não lineares entre perfis de consumo.
- **Clustering (K-Means):** Segmentação de "Tribos de Consumo" para marketing direcionado.

7. Protocolo de Entrega e Portfólio

Para validação profissional e acadêmica, o analista deve consolidar os resultados:

1. **Dashboard Interativo:** Além do Python, integre os insights em um dashboard no **Looker Studio** para visualização executiva.
2. **Relatório Final:** Compile este guia, os gráficos gerados e suas conclusões em um documento **PDF**.
3. **Apresentação Executiva:** Grave um vídeo de até **3 minutos** (MP4) demonstrando o funcionamento do código e os 3 principais insights de negócio.
4. **Sincronização GitHub:** Todos os artefatos (Notebook .ipynb, Relatório PDF e Vídeo) devem ser commitados no seu repositório MEUS PROJETOS. Este projeto transforma

dados brutos em vantagem competitiva, provando que o valor real do Big Data não está no volume, mas na capacidade de extrair padrões que salvam negócios.